如何在特定條件下透過調整學習習慣達到最理想學業成績

1 引言（Introduction）

1.1 動機（Motivation）

在教育數據挖掘領域，預測學生學業表現（Academic Performance）通常依賴於學習時間（Study Hours）這一單一指標。然而，現代學生的生活型態日益複雜，數位娛樂（如社群媒體、Netflix）、睡眠品質以及心理健康等多重因素交織，共同影響最終的考試成績。傳統的線性假設往往忽略了「邊際效益遞減」現象——即投入過多時間學習可能無法帶來等比例的分數增長。為了制定精準的學習策略，本研究欲從多變數的角度，探討這些行為變數如何交互影響成績。

1.2 科學問題（Scientific Questions）

本研究利用 Kaggle 的學生行為數據集，旨在回答以下三個核心問題：

1. 透過不同的常見迴歸模型效能比較，分析各習慣對成績的影響、比較其的效能並找出最低 $RMSE$ 的模型。
2. 利用非線性非線性驗證，學習時間對成績的貢獻是否符合飽和模型，是否存在明顯上限。
3. 在特定時間與行為限制條件下，找出最適合此條件的學習時間分配。

2 初步分析（Preliminary Analysis）

2.1 資料分佈與結構

本研究分析了 1000 筆學生資料，共有 16 項特徵值，包含：

- `student_id`：學生學號

- `study_hours_per_day`：一天讀書時間
- `age`：年齡
- `social_media_hours`：社群媒體使用時間
- `netflix_hours`：Neflix 使用時間
- `attendance_percentage`：課堂出席率
- `sleep_hours`：睡眠時間
- `exercise_frequency`：一周的運動頻率
- `mental_health_rating`：心理健康
- `exam_score`：學業成績

其中，目標值 `exam_score` 呈現單峰且略微右偏（right-skewed）的分佈，顯示大多數學生分數集中在中上區間，無極端離群值，適合進行參數化建模。

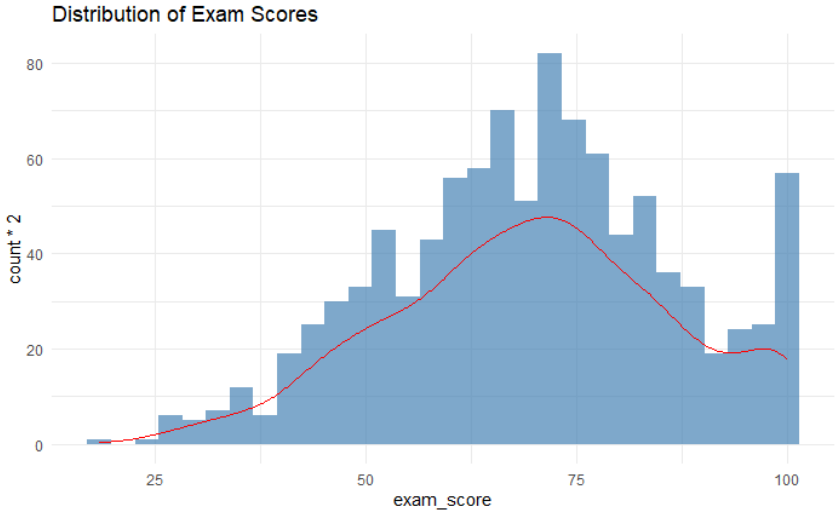

2.2 各個數值特徵與 `exam_score` 的簡易關係

由下圖可以看到 `exam_score` 與 `study_hours_per_day` 有很強的正向關係，與 `sleep_hours`, `exercise_frequency` 和 `mental_health_rating` 有些微的正向關係；而與 `social_media_hours` 和 `netflix_hours` 有些微的負向關係；與其他變異的關係沒有到那麼明顯。

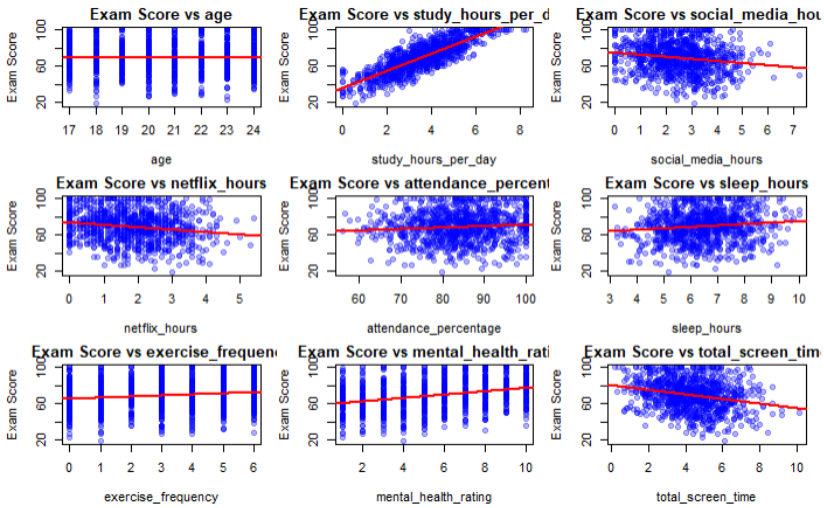

3 Methodology (研究方法)

3.1 評估各模型效能

本研究採用 80% 訓練集與 20% 測試集的隨機劃分，並透過 100 次迭代驗證（100-iteration Bootstrap）來評估模型的穩健性。我們建立並比較了四種線性回歸模型的 RMSE (Root Mean Squared Error) 與 R^2：

1. **OLS (Ordinary Least Squares):**
   目標非常單純，就是畫一條線，讓所有資料點到這條線的垂直距離平方和 (RSS, Residual Sum of Squares) 最小。

$$\text{Minimize} \sum_{i=1}^{n}(y_i - \hat{y}_i)^2 \tag{1}$$

   結果： RMSE = 5.503, $R^2 = 0.8910$

2. **StepAIC (Stepwise Regression):**
   利用 MASS 套件中的 `stepAIC` 函數，透過 AIC 準則進行雙向變數篩選，保留最具解釋力的特徵。

$$AIC = 2k - 2\ln(L) \tag{2}$$

   其中：

   - L (Likelihood) 模型擬合度：模型預測越準，這項數值越高，AIC 就越低。
   - k (Number of parameters) 變數數量：變數用越多，模型越複雜，這項數值越高，AIC 就越高（懲罰項）。

   結果： RMSE = 5.349, $R^2 = 0.8988$
   最後保留變數如下圖所示：

```
Coefficients:
                       Estimate Std. Error t value Pr(>|t|)
(Intercept)             6.66832    2.11387   3.155  0.00167 **
study_hours_per_day     9.48872    0.12636  75.091  < 2e-16 ***
social_media_hours     -2.57984    0.15787 -16.341  < 2e-16 ***
netflix_hours          -2.36617    0.17311 -13.668  < 2e-16 ***
attendance_percentage   0.14001    0.01995   7.017 4.87e-12 ***
sleep_hours             2.05989    0.15254  13.504  < 2e-16 ***
diet_qualityGood       -0.84072    0.41625  -2.020  0.04374 *
diet_qualityPoor       -0.68982    0.52351  -1.318  0.18799
exercise_frequency      1.51806    0.09297  16.329  < 2e-16 ***
mental_health_rating    1.94144    0.06615  29.349  < 2e-16 ***
```

3. **Ridge Regression:**
   為了解決 OLS 「太過自由、容易過度擬合」的問題，Ridge 選擇「懲罰」那些太大的係數。除了要讓預測誤差最小，還希望係數 (β) 越小越好。

$$\text{Minimize } \underbrace{\sum (y_i - \hat{y}_i)^2}_{\text{誤差}} + \underbrace{\lambda \sum_{j=1}^{p} \beta_j^2}_{\text{懲罰項 (L2)}} \tag{3}$$

   結果： RMSE $= 5.493$, $R^2 = 0.8934$

4. **Lasso Regression:**
   處理多重共線性並進行特徵縮減。與 Ridge 很像，但懲罰的方式稍微不同，同樣希望係數小，但使用的是「絕對值」懲罰。

$$\text{Minimize } \sum (y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^{p} |\beta_j| \tag{4}$$

   結果： RMSE $= 5.355$, $R^2 = 0.8979$

   最後保留變數如下圖所示：

```
(Intercept)                          8.0837366
age                                  .
genderMale                           0.1646760
genderOther                          .
study_hours_per_day                  9.5714600
social_media_hours                  -2.4650686
netflix_hours                       -2.0343404
part_time_jobYes                     .
attendance_percentage                0.1272151
sleep_hours                          1.9068124
diet_qualityGood                    -0.5494228
diet_qualityPoor                     .
exercise_frequency                   1.4411099
parental_education_levelHigh School  .
parental_education_levelMaster      -0.1664241
parental_education_levelNone        -0.1569577
internet_qualityGood                -0.1087710
internet_qualityPoor                 .
mental_health_rating                 1.8608284
extracurricular_participationYes     0.1137147
```

3.2 邊際效應遞減關係

透過散佈圖與 LOESS 平滑曲線分析，觀察到學習時間與成績間雖存在正相關，但並非完美線性關係。成績的上升幅度隨學習時間增加逐漸趨緩（邊際效益遞減）。

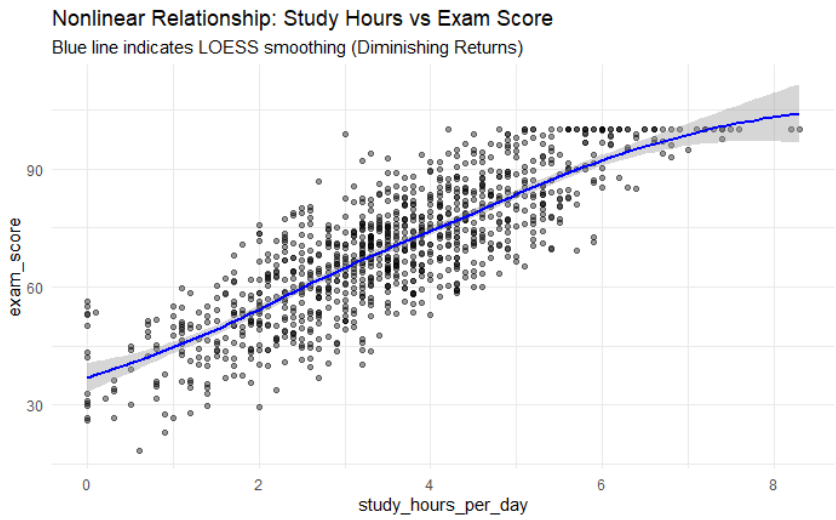

3.3 學習時間分配

本研究設定一組特定情境：假設有一位學生非常喜歡社交（`social_media_hours` ≥ 6），且經常缺課（`attendance_percentage` 僅 60%）。幸運的是，該生並不排斥運動，一次運動的時間為 40 分鐘；心理健康評分（`mental_health_rating`）維持在 8 分，並每日安排約 2 小時觀看 Netflix。並假設該生此學習修習 18 學分，且每一學分代表一週內有一小時的課。

限制式：

$$\text{StudyHoursPerDay} + \text{SocialMediaHours} + \text{NetflixHours} + \text{SleepHours} +$$
$$\text{ExerciseFrequency} \cdot \frac{2}{21} + \text{AttendancePercentage} \cdot \frac{18}{700} < 20$$
$$0 < \text{StudyHoursPerDay} < 8.3, \quad 6 < \text{SocialMediaHours} < 7.2$$
$$3 < \text{SleepHours} < 10, \quad \text{NetflixHours} = 2$$
$$0 < \text{ExerciseFrequency} < 6, \quad \text{AttendancePercentage} = 60$$
$$\text{MentalHealthRating} = 8$$

4 實證結果（Data Application）

4.1 模型比較

模型	平均 RMSE	平均 R^2	評估
StepAIC	**5.349**	**0.8988**	最佳表現
Lasso	5.359	0.8985	表現接近 StepAIC
Ridge	5.509	0.8927	稍弱
Random Forest	7.105	0.8220	表現最差

透過迭代 100 次後的結果得到各個模型的較為穩定的 RMSE 以及 R^2，可以得知 StepAIC 在兩者上都有著最佳的表現，因此篩選出的變數及為本研究中對學業成績具有影響的變數，包含：

- `study_hours_per_day`：一天讀書時間
- `social_media_hours`：社群媒體使用時間
- `netflix_hours`：Neflix 使用時間
- `attendance_percentage`：課堂出席率
- `sleep_hours`：睡眠時間
- `exercise_frequency`：一周的運動頻率
- `mental_health_rating`：心理健康

4.2 非線性模型結果（NLS）

NLS 模型參數估計為 $a = 97.71$，$b = 0.385$，成功擬合飽和效應：

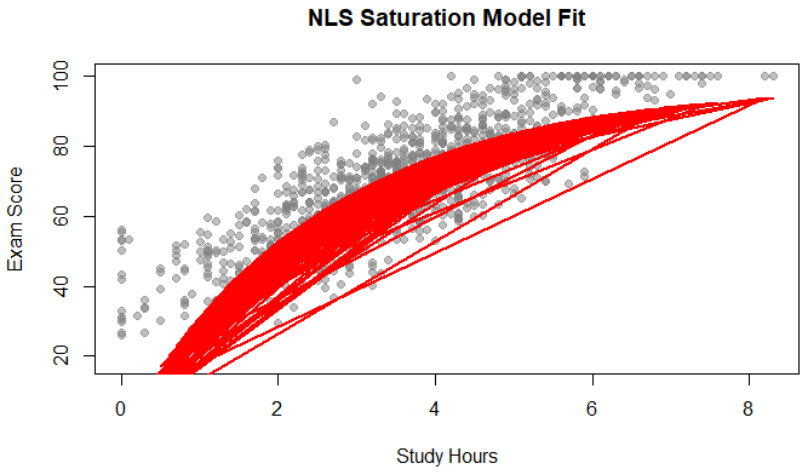

代表學習時間對成績的貢獻在此研究中存在上限，此上限 97.7。

4.3 學習時間分配（Strategy Optimization）

由 4.1 可以得出最佳的目標式為：

$$\begin{aligned}\text{ExamScore} = {} & 9.62969 \cdot \text{StudyHoursPerDay} - 2.58072 \cdot \text{SocialMediaHours} \\ & - 2.43742 \cdot \text{NetflixHours} + 0.13701 \cdot \text{AttendancePercentage} \\ & + 2.01351 \cdot \text{SleepHours} + 1.44285 \cdot \text{ExerciseFrequency} + 1.95267 \cdot \text{MentalHealthRating}\end{aligned}$$

利用 `lpSolve` 在扣除生活緩衝時間後、每日總時間 20 小時的限制下進行求解，我們得出了最佳作息配置表。結果顯示，模型建議採取「**高強度學習**」**搭配**「**最低限度睡眠**」的策略以最大化分數。

變數	最佳值	係數
study_hours_per_day	3.89	9.62969
social_media_hours	6.00	-2.58072
netflix_hours	2.00	-2.43742
attendance_percentage	60.00	0.13701
sleep_hours	6.00	2.01351
exercise_frequency	6.00	1.44285
mental_health_rating	8.00	1.95267

預測成績：

$$\boxed{\text{Predicted Maximum Score: } 68.17}$$

5 結論（Conclusion）

本研究整合統計建模與最佳化，得出以下發現：

1. 在此類結構化數據中，StepAIC 線性模型表現優異 ($R^2 \approx 0.90$)，由其模型可知對學業成績有影響的因子如下：`study_hours_per_day`, `social_media_hours`、`netflix_hours`, `attendance_percentage`、`sleep_hours`、`exercise_frequency`、`mental_health_rating` 其中以 `study_hours_per_day` 具有最高的相關性。

2. NLS 模型證實了學習時間對成績的貢獻存在上限 ($a \approx 97.7$)，說明了或無限延長讀書時間並非突破滿分的唯一途徑，由 4.3 的結果可以得知，選擇提升 `exercise_frequency` 反而比提升 `study_hours_per_day` 更有優勢。

3. 4.3 的結果給出了 68.17 分的預測極值，可以看到數學上的最佳解往往位於限制條件的邊界（Boundary Solutions），在應用時必須考量生理健康的「軟限制」，尋求分數與健康的平衡點。