透過機器學習模型
分析紅酒品質

林秉澄 112031143
蔡旻宸 112032056
鍾沅峻 112031118
凃智中 113034008
洪廷旭 112023063

研究動機與目的

今日對於紅酒工業品質控制有著巨大的挑戰，傳統感官品鑑因主觀資訊量大及無法即時生產化而不能滿足業產需求。此影響在葡萄酒價格有著巨大差距，如拉菲1982 (紅酒名)，其價格為三十萬元一瓶，是正常年份五十倍。

由於生產紅酒的具有多種關鍵參數 (發酵條件、原材料...) ，本研究希望在化學成份與品質之間建立預測模型模型，結合工業 4.0 ：制程參數優化、品質標准化、提前品質管理，為紅酒產業的數位化轉型提供數據支撐，從經驗式管理轉向智慧製程控制。

數據來源

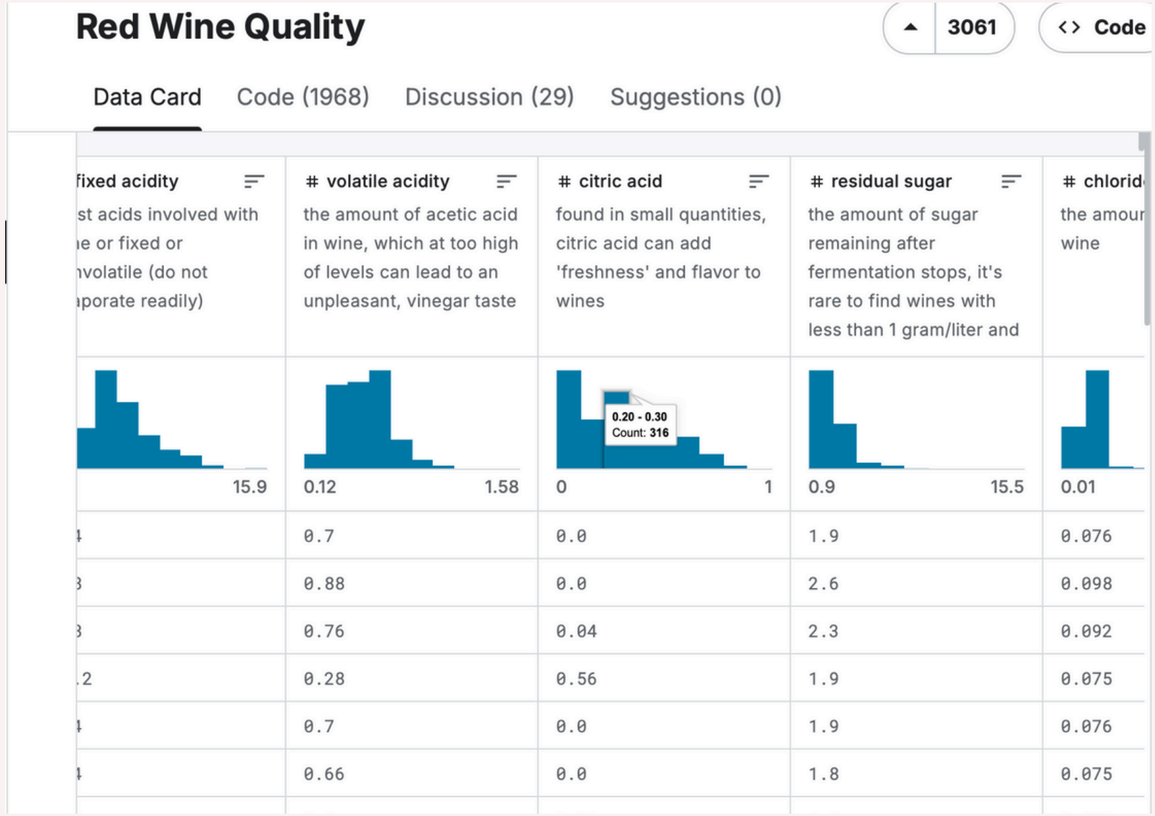

資料來源：KAGGLE-RED WINE QUALITY

特徵介紹

目標變數:Quality

其他特徵

- Fixed acidity
- Volatile acidity
- Citric acid
- Residual sugar
- Chlorides
- Free Total sulfur dioxide
- Density, pH
- Sulphates, Alcohol

評鑑方式

酒的品質分數介於0到10，每個酒樣至少由三位品酒師盲測，取中位數最為最終分數

研究方法

資料清洗	去除缺失值、處理極端值
特徵篩選	找出對預測最有幫助的資料
建模預測	根據特徵選擇最合適的模型
結果分析	根據結果及模型進行分析討論

資料清洗　特徵分布

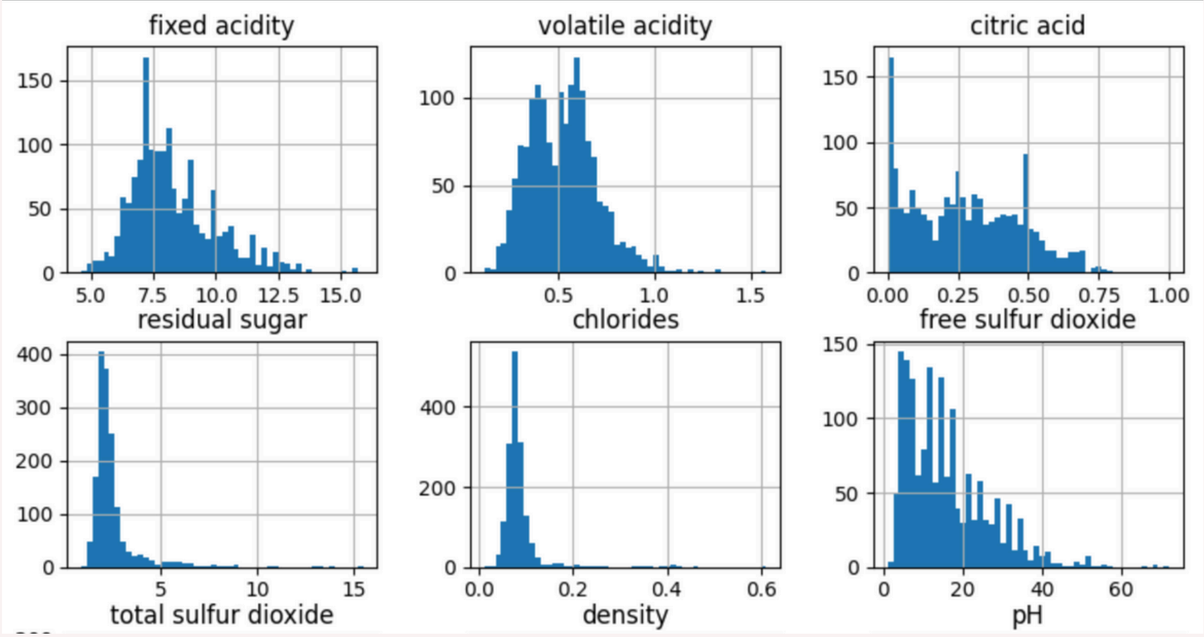

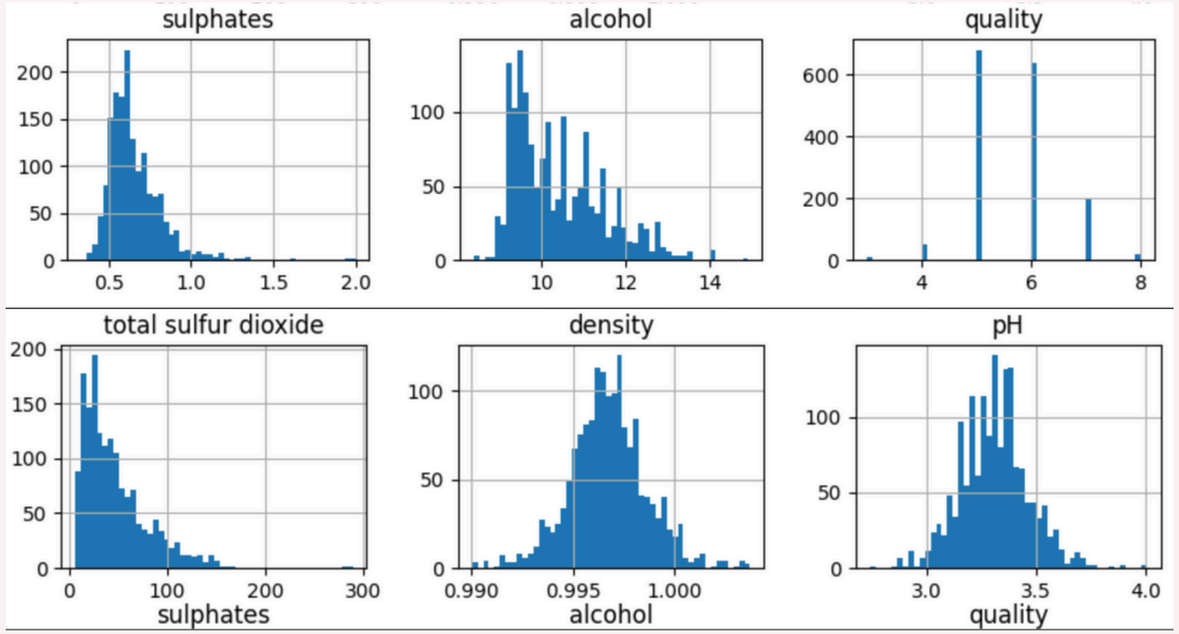

視覺化資料的同時，觀察品質分佈與變因數值分佈

- 品質集中於 5、6 分，明顯是最常見的等級
- 特徵都是成鐘型曲線的分布，只是偏度不同
- 單靠直方圖無法直接看到「品質 vs. 特徵」的精確關係

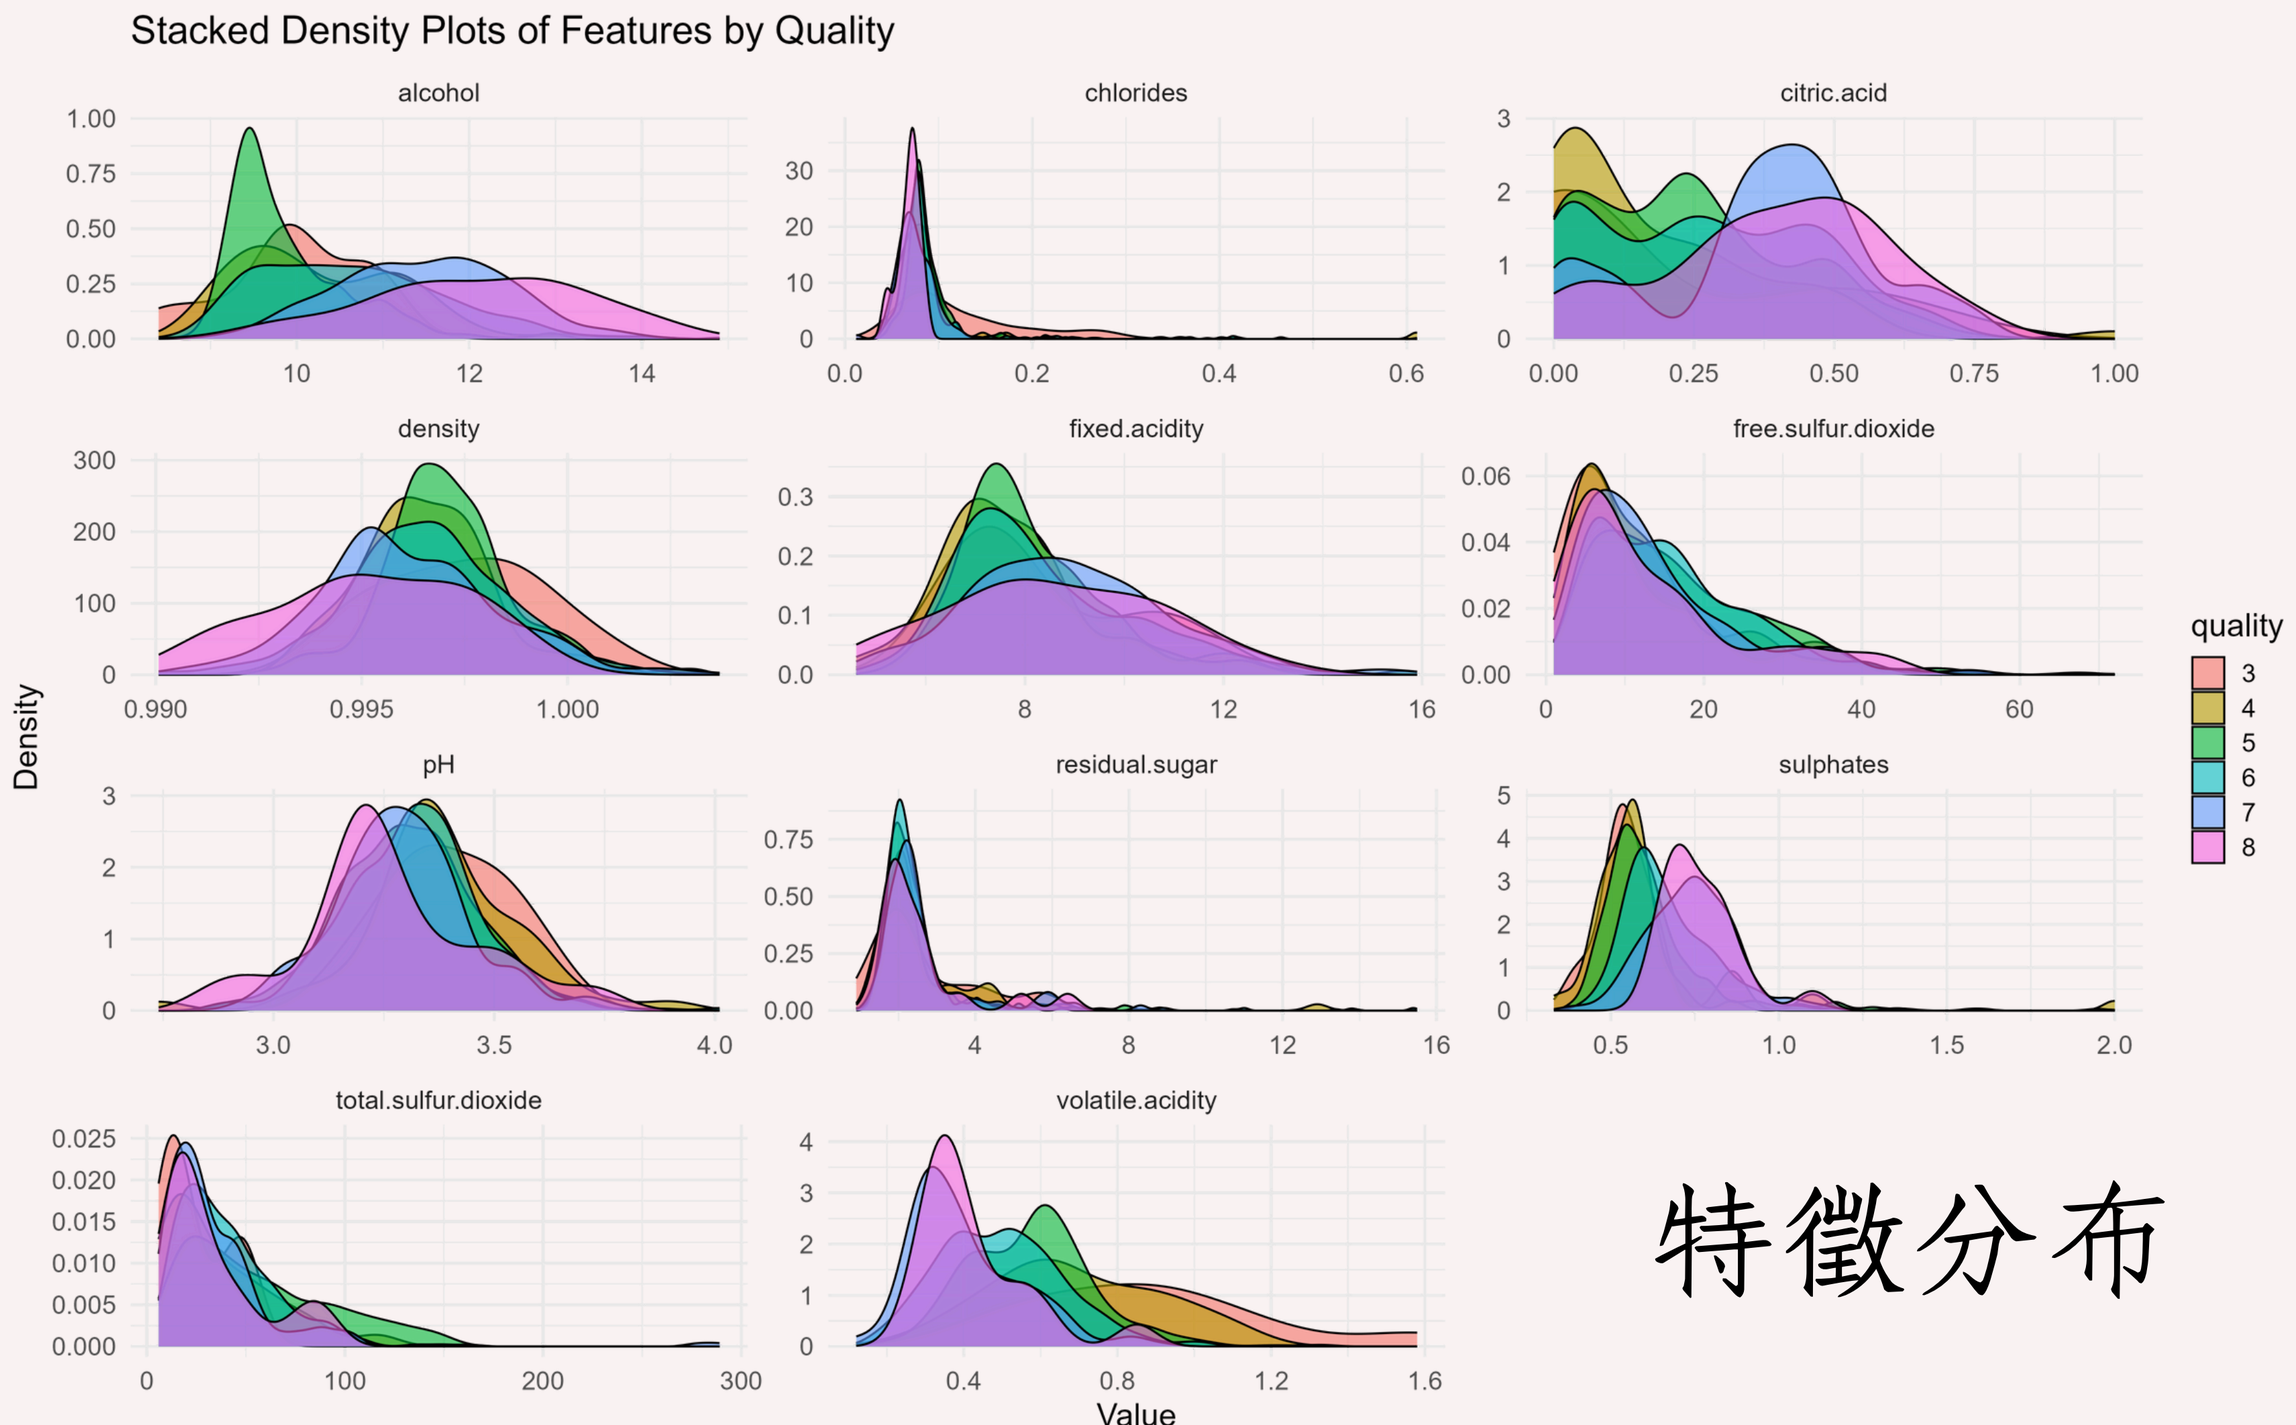
Stacked Density Plots of Features by Quality
alcohol
chlorides
citric.acid
density
fixed.acidity
free.sulfur.dioxide
pH
residual.sugar
sulphates
total.sulfur.dioxide
volatile.acidity
Density
Value
quality
3
4
5
6
7
8

特徵分布

資料清洗　處理極端值

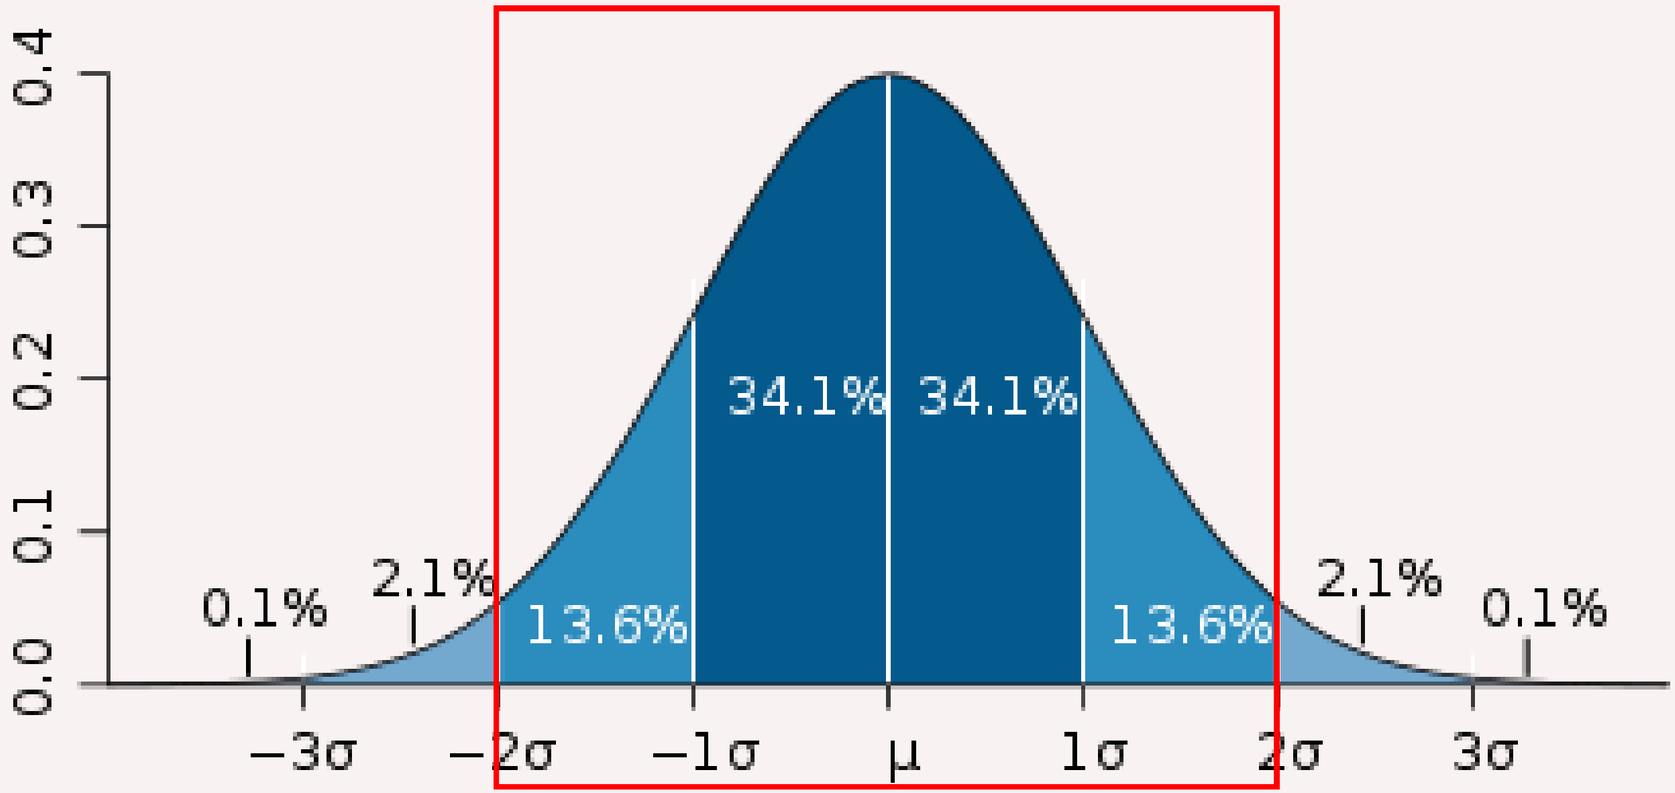

各個特徵的每一個評級都只取中間的95.6%

→ 因為沒有缺值，故不須處理

特徵篩選

紅酒品質各種數值下的數量

品質	數量
3	10
4	53
5	681
6	638
7	199
8	18

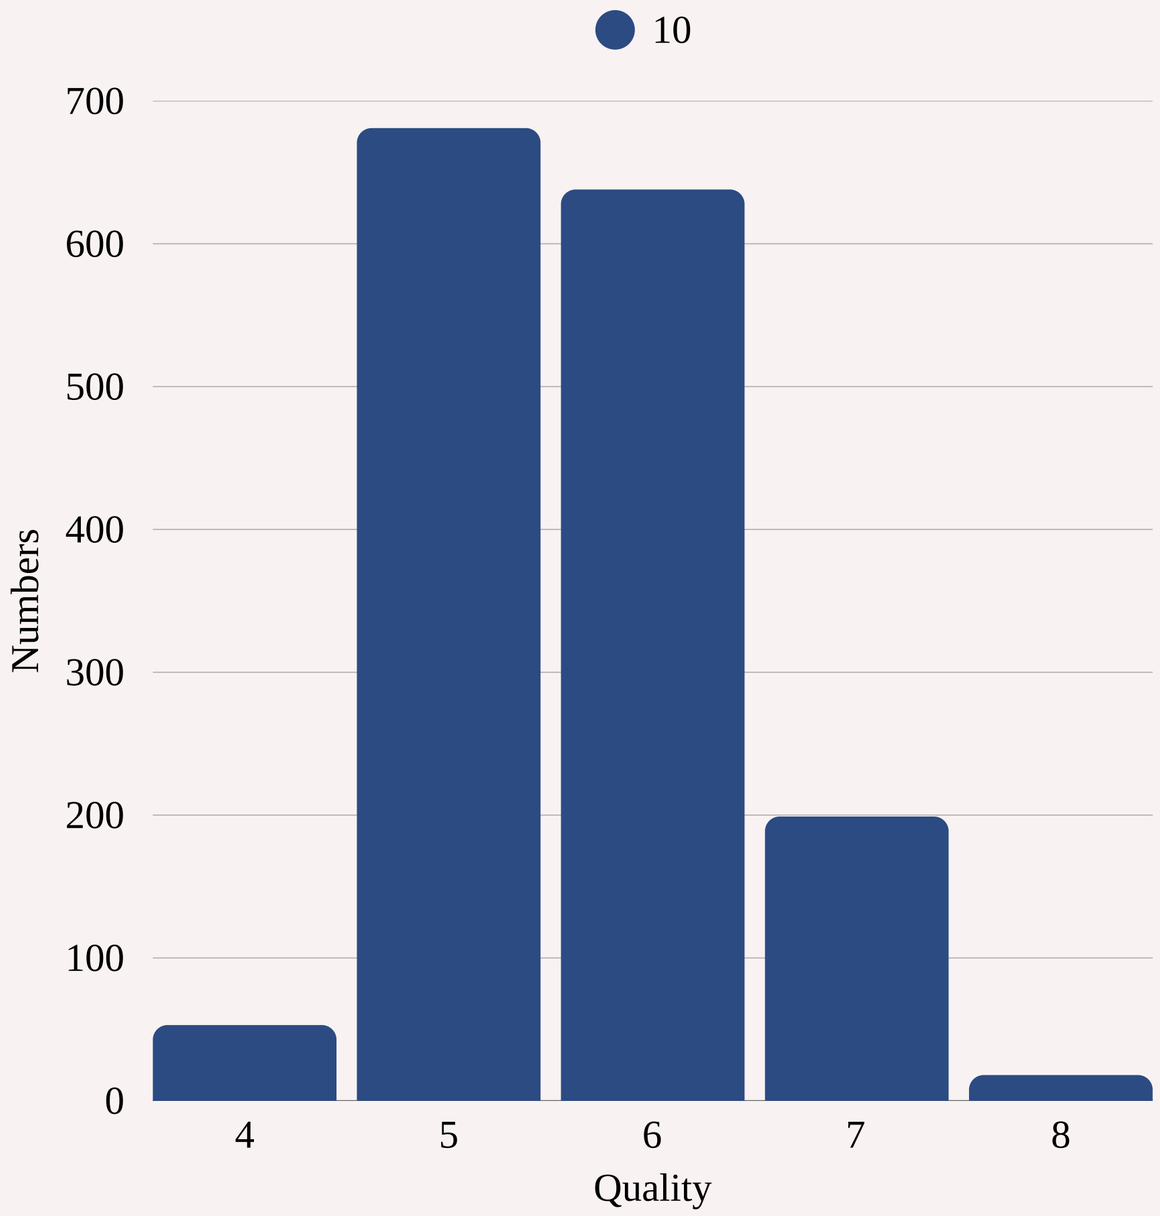

特徵篩選　紅酒品質 vs. 不同因素

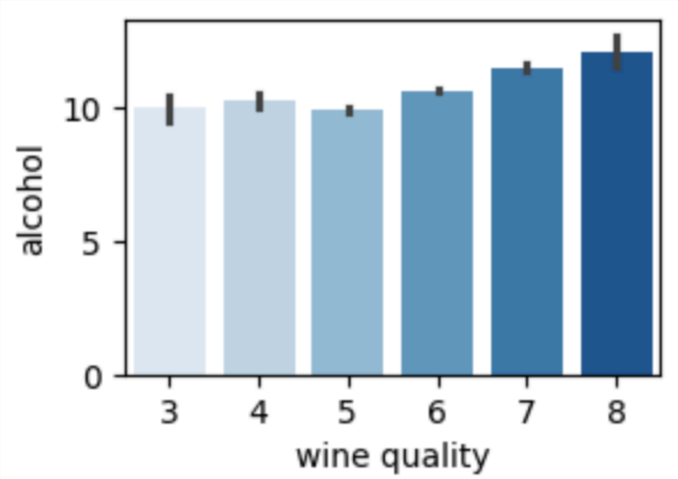

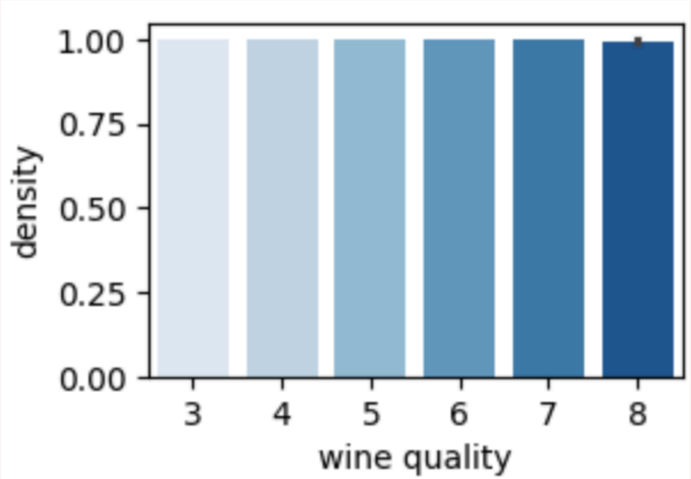

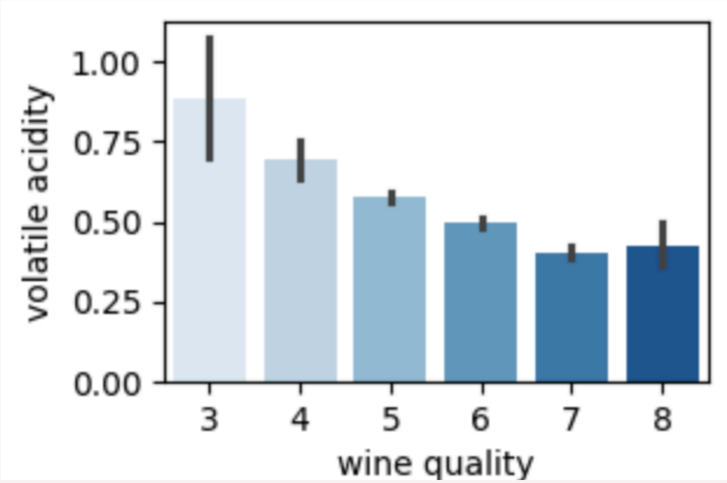

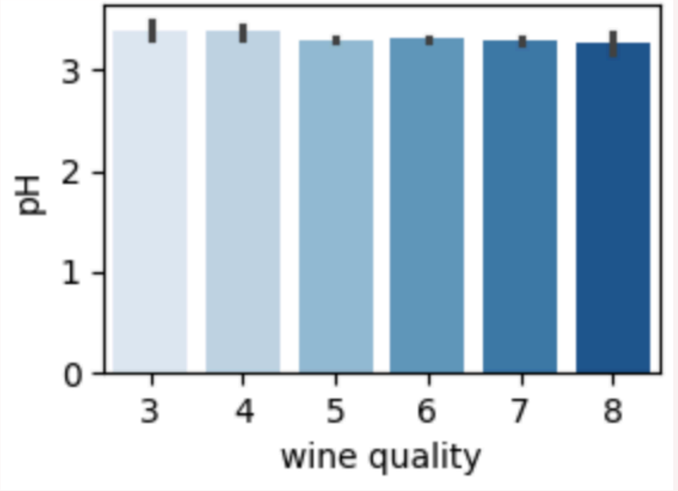

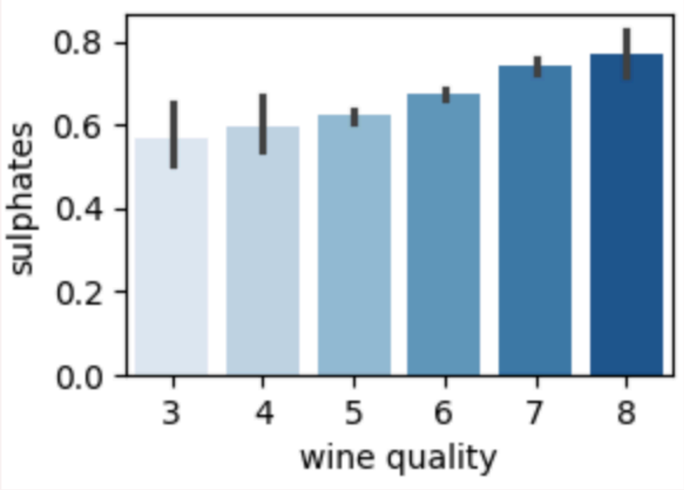

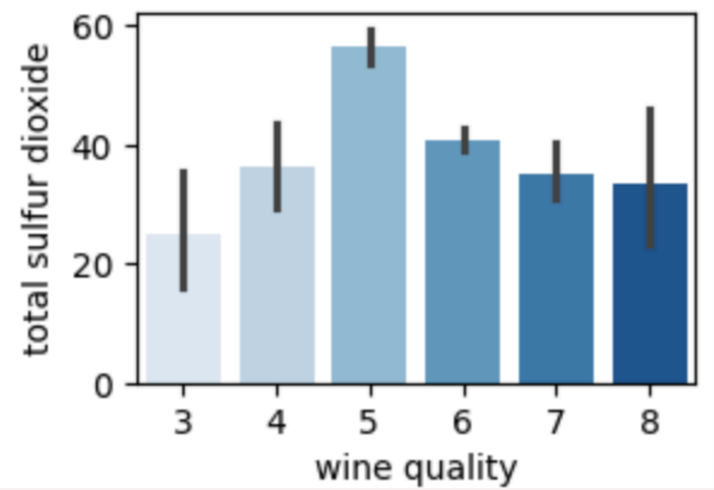

紅酒品質 vs. 不同因素

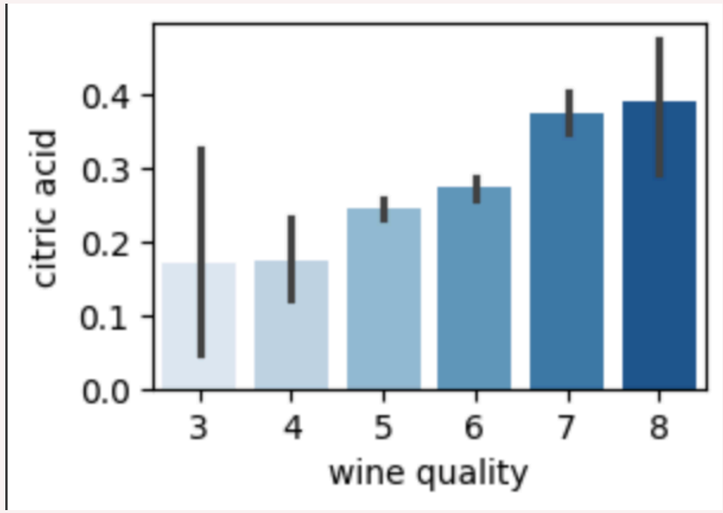
citric acid
0.0
0.1
0.2
0.3
0.4
3
4
5
6
7
8
wine quality

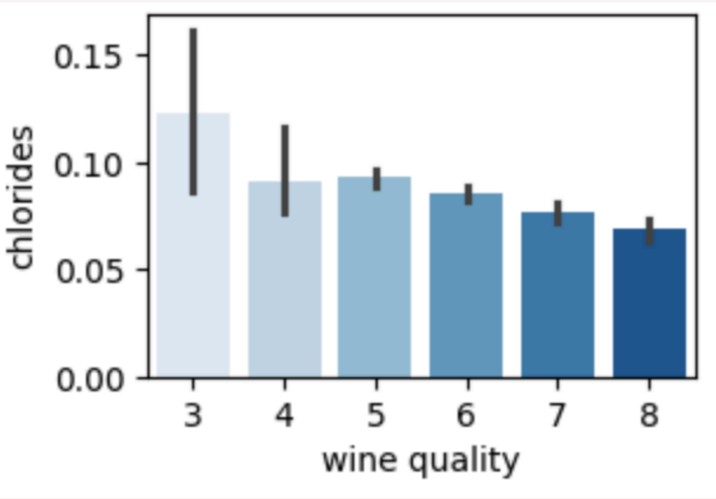
chlorides
0.00
0.05
0.10
0.15
3
4
5
6
7
8
wine quality

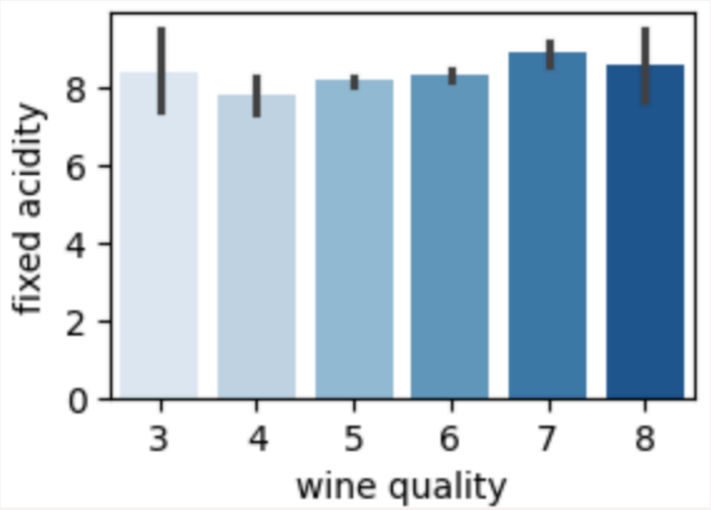
fixed acidity
0
2
4
6
8
3
4
5
6
7
8
wine quality

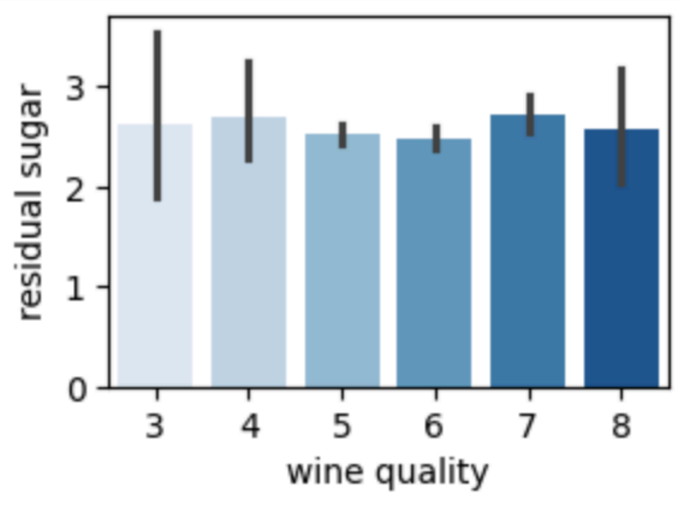
residual sugar
0
1
2
3
3
4
5
6
7
8
wine quality

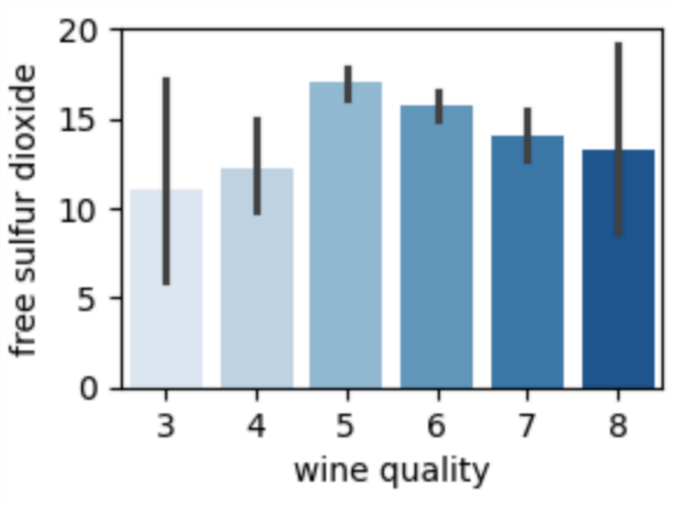
free sulfur dioxide
0
5
10
15
20
3
4
5
6
7
8
wine quality

特徵篩選

紅酒品質和不同因素分析

從各變數平均值可看出：

- 硫酸鹽、酒精、檸檬酸明顯與紅酒品質有正相關
- 揮發酸度、氯化物明顯與紅酒品質有負相關
- 其他變數尚無法明顯看出相關性

接著可以製作熱圖詳細對比各變數與紅酒品質的相關係數

特徵篩選 熱力圖

正相關

酒精濃度 (0.48)

硫酸鹽 (0.25)

檸檬酸 (0.23)

負相關

揮發酸 (-0.39)

密度 (-0.17)

總二氧化硫 (-0.19)

氯化物 (-0.13)

相關性極低(~0)

fixed acidity / residual sugar

free sulfur dioxide / pH

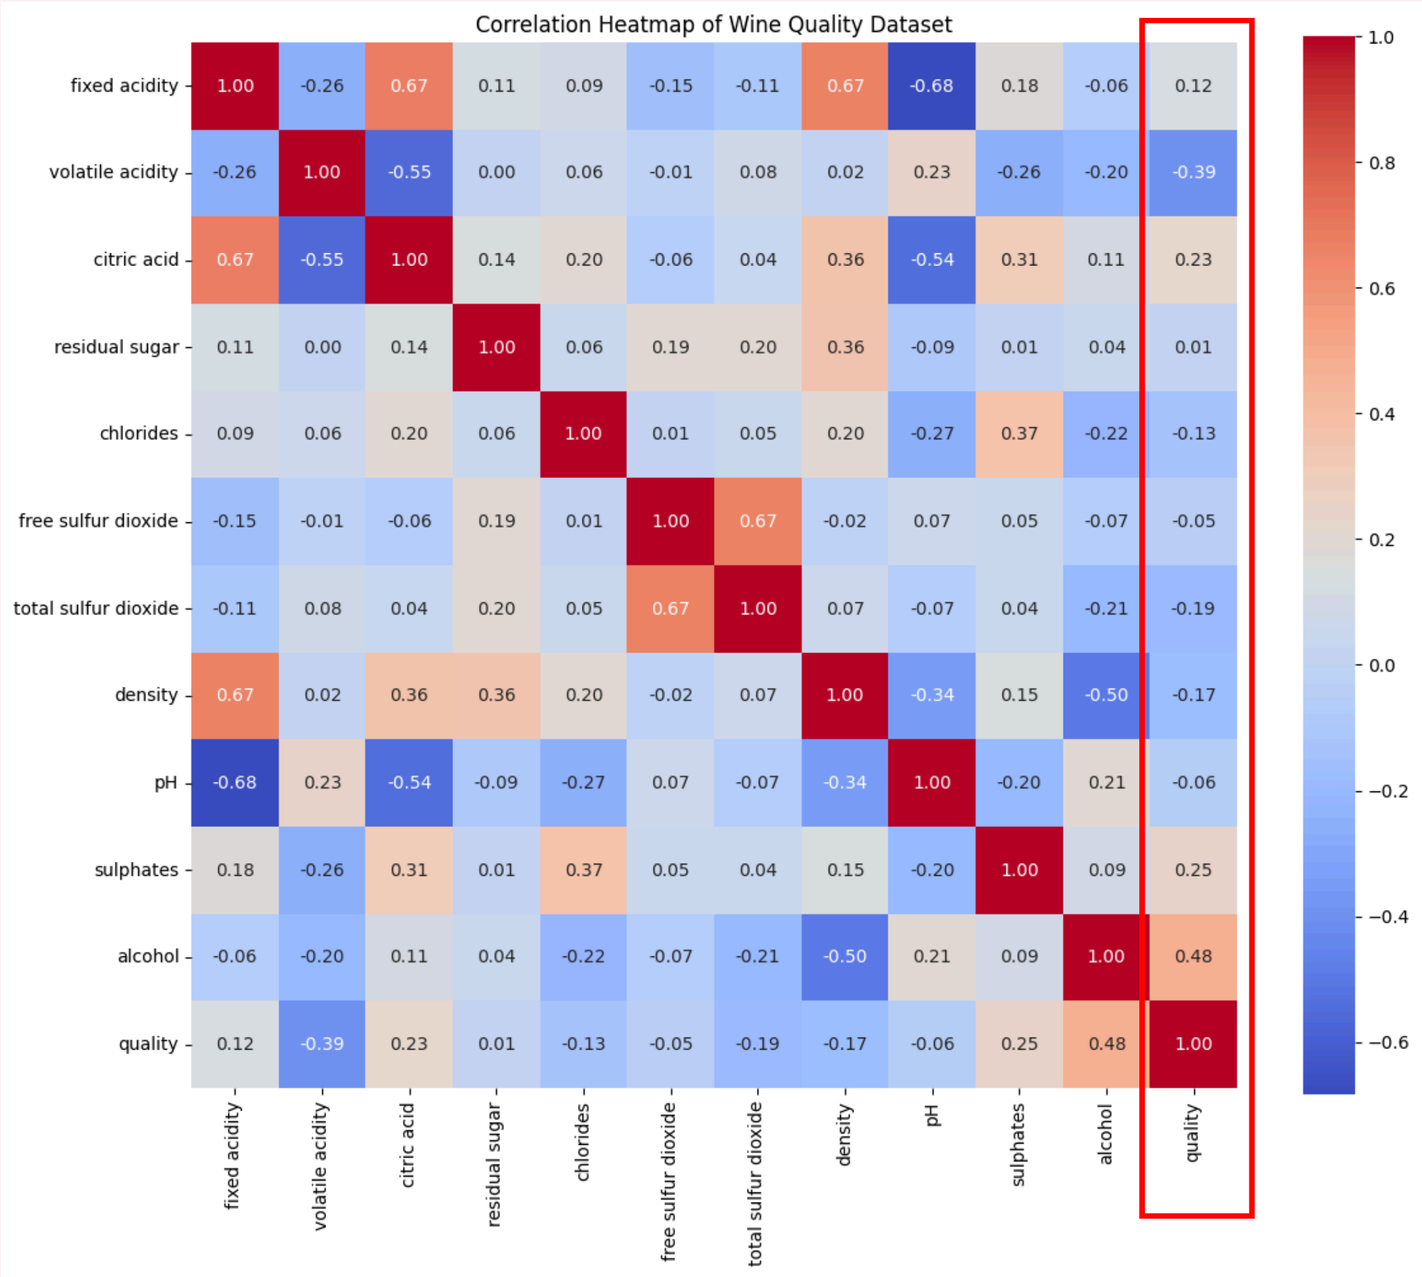

特徵篩選　穩定選擇法

資料 → 隨機取出70%筆資料 → 子資料 → 建立回歸跑StepAIC → 留下AIC最小時的特徵

重複一百次，並記錄每次留下的特徵

特徵篩選　特徵出現次數

變數名稱	次數
fixed.acidity	100
volatile.acidity	100
citric.acid	100
chlorides	100
free.sulfur.dioxide	100
total.sulfur.dioxide	100
density	100
pH	100
sulphates	100
alcohol	100

變數名稱	次數
volatile.acidity:total.sulfur.dioxide	100
citric.acid:pH	100
fixed.acidity:pH	95
total.sulfur.dioxide:density	95
free.sulfur.dioxide:sulphates	94
residual.sugar	93
citric.acid:alcohol	93
density:sulphates	93
free.sulfur.dioxide:density	89
total.sulfur.dioxide:alcohol	89

建模預測

訓練集	原始資料70%
測試集	原始資料30%

模型	線性回歸
評分表準	RMSE

隨機切換
訓練和測試集

重複3000次
使RMSE穩定

由出現次數
選取特徵

跑線性回歸

RMSE

不斷重複直到找到最好的特徵

建模預測　模型與最佳特徵

最佳RMSE:0.577

```
Residual standard error: 0.6253 on 1535 degrees of freedom
Multiple R-squared:  0.4131, Adjusted R-squared:  0.4012
F-statistic: 34.85 on 31 and 1535 DF,  p-value: < 2.2e-16
```

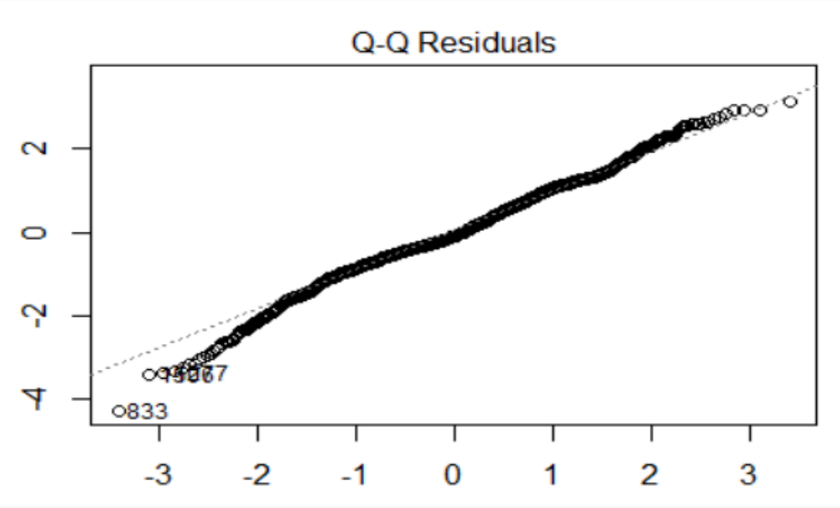

Q-Q Plot

最佳特徵

```
fixed.acidity
volatile.acidity
citric.acid
chlorides
free.sulfur.dioxide
total.sulfur.dioxide
density
pH
sulphates
alcohol
residual.sugar
volatile.acidity:total.sulfur.dioxide
citric.acid:pH
fixed.acidity:pH
total.sulfur.dioxide:density
free.sulfur.dioxide:sulphates
citric.acid:alcohol
density:sulphates
free.sulfur.dioxide:density
total.sulfur.dioxide:alcohol
pH:sulphates
fixed.acidity:chlorides
free.sulfur.dioxide:alcohol
chlorides:free.sulfur.dioxide
fixed.acidity:alcohol
fixed.acidity:sulphates
chlorides:density
free.sulfur.dioxide:total.sulfur.dioxide
fixed.acidity:free.sulfur.dioxide
volatile.acidity:alcohol
total.sulfur.dioxide:residual.sugar
```

結果分析

模型結果

最佳RMSE	0.577
R-Squre	0.4012

相對誤差:<u>11.5%</u>

ex：如果實際品質是5

預測值有大約68%的機率

落在[4.423, 5.577] 區間

→ 模型仍有約60%的變異無法解釋。

雖然模型解釋力不高

但具有不錯的預測力

結果分析

統計分析

做ANOVA

*** <0.001

** <0.01

* <0.05

Variable	Estimate	P-value	Significance
(Intercept)	-109.8	0.057415	.
fixed.acidity	-0.6354	0.017496	*
volatile.acidity	-4.128	0.000868	***
citric.acid	614.0	0.024613	*
chlorides	-885.6	0.00741	**
free.sulfur.dioxide	-37.7	0.000193	***
total.sulfur.dioxide	1.648	0.000901	***
density	372.9	0.000828	***
pH	-3.749	4.49e-08	***
sulphates	267.0	0.000971	***
alcohol	3.682	0.000772	***
residual.sugar	-0.03547	0.176638	
volatile.acidity:total.sulfur.dioxide	-0.03489	0.000102	***
citric.acid:pH	-3.241	4.28e-05	***
fixed.acidity:pH	28.88	0.000168	***
total.sulfur.dioxide:density	-1.638	0.000884	***
free.sulfur.dioxide:sulphates	-0.02734	0.014407	*
citric.acid:alcohol	0.4185	0.00132	**
density:sulphates	-277.0	0.000727	***
free.sulfur.dioxide:density	3.711	0.022445	*
total.sulfur.dioxide:alcohol	-0.002649	0.004322	**
pH:sulphates	2.522	0.000453	***
fixed.acidity:chlorides	-1.217	0.003503	**
free.sulfur.dioxide:alcohol	0.006757	0.012007	*
chlorides:free.sulfur.dioxide	-0.08513	0.046248	*
fixed.acidity:alcohol	-0.03734	0.001827	**
fixed.acidity:sulphates	0.2822	0.004964	**
chlorides:density	898.1	0.007174	**
fixed.acidity:total.sulfur.dioxide	-9.245e-05	0.047248	*
fixed.acidity:free.sulfur.dioxide	-0.0004422	0.755637	
volatile.acidity:alcohol	0.2416	0.035067	*
total.sulfur.dioxide:residual.sugar	0.0006901	0.028407	*

結果分析 檢定分析

變數	關聯方向	顯著性	說明
`alcohol`	正相關	`*** 顯著`	酒精濃度越高，品質評分越高，是最具正向影響的變數之一。
`sulphates`	正相關	`*** 顯著`	適量硫酸鹽有助於風味或保存，與品質有明顯正相關。
`citric.acid`	正相關	`* 顯著`	檸檬酸可改善酸味層次，略有助於提升品質。
`pH:sulphates`	正相關	`*** 顯著`	酸鹼值與硫酸鹽搭配能提升品質，有協同效果。
`citric.acid:alcohol`	正相關	`** 顯著`	檸檬酸與酒精的搭配能強化口感與品質。
`volatile.acidity`	負相關	`*** 顯著`	含量高會產生刺鼻酸味，是最具負面影響的變數。
`pH`	負相關	`*** 顯著`	酸感不足會讓口感變淡，pH 越高品質越差。
`chlorides`	負相關	`** 顯著`	鹽分過多會影響風味與平衡，導致品質下降。

變數	關聯方向	顯著性	說明
`total.sulfur.dioxide:density`	負相關	`*** 顯著`	SO_2 與密度交互下品質下降，可能因風味被壓抑。
`total.sulfur.dioxide:alcohol`	負相關	`** 顯著`	高酒精搭配過多 SO_2 不利風味，品質下降。
`density:sulphates`	負相關	`*** 顯著`	密度高時硫酸鹽反而減分，失去原有正效應。
`fixed.acidity:pH`	正相關（交互）	`*** 顯著`	在特定酸鹼組合下酸度平衡佳，有助提升品質。
`free.sulfur.dioxide`	負相關	`** 顯著`	雖然單獨為負，與其他變數有交互作用，需搭配理解。
`residual.sugar`	無明顯關聯	`✗ 不顯著`	與品質關係不明顯，可能非主要預測因子。
`free.sulfur.dioxide:alcohol`	無明顯關聯	`✗ 不顯著`	無顯著統計支持，可能僅具輔助效果。
`fixed.acidity:free.sulfur.dioxide`	無明顯關聯	`✗ 不顯著`	對品質解釋力低，不具統計意義。

後續應用

最佳化

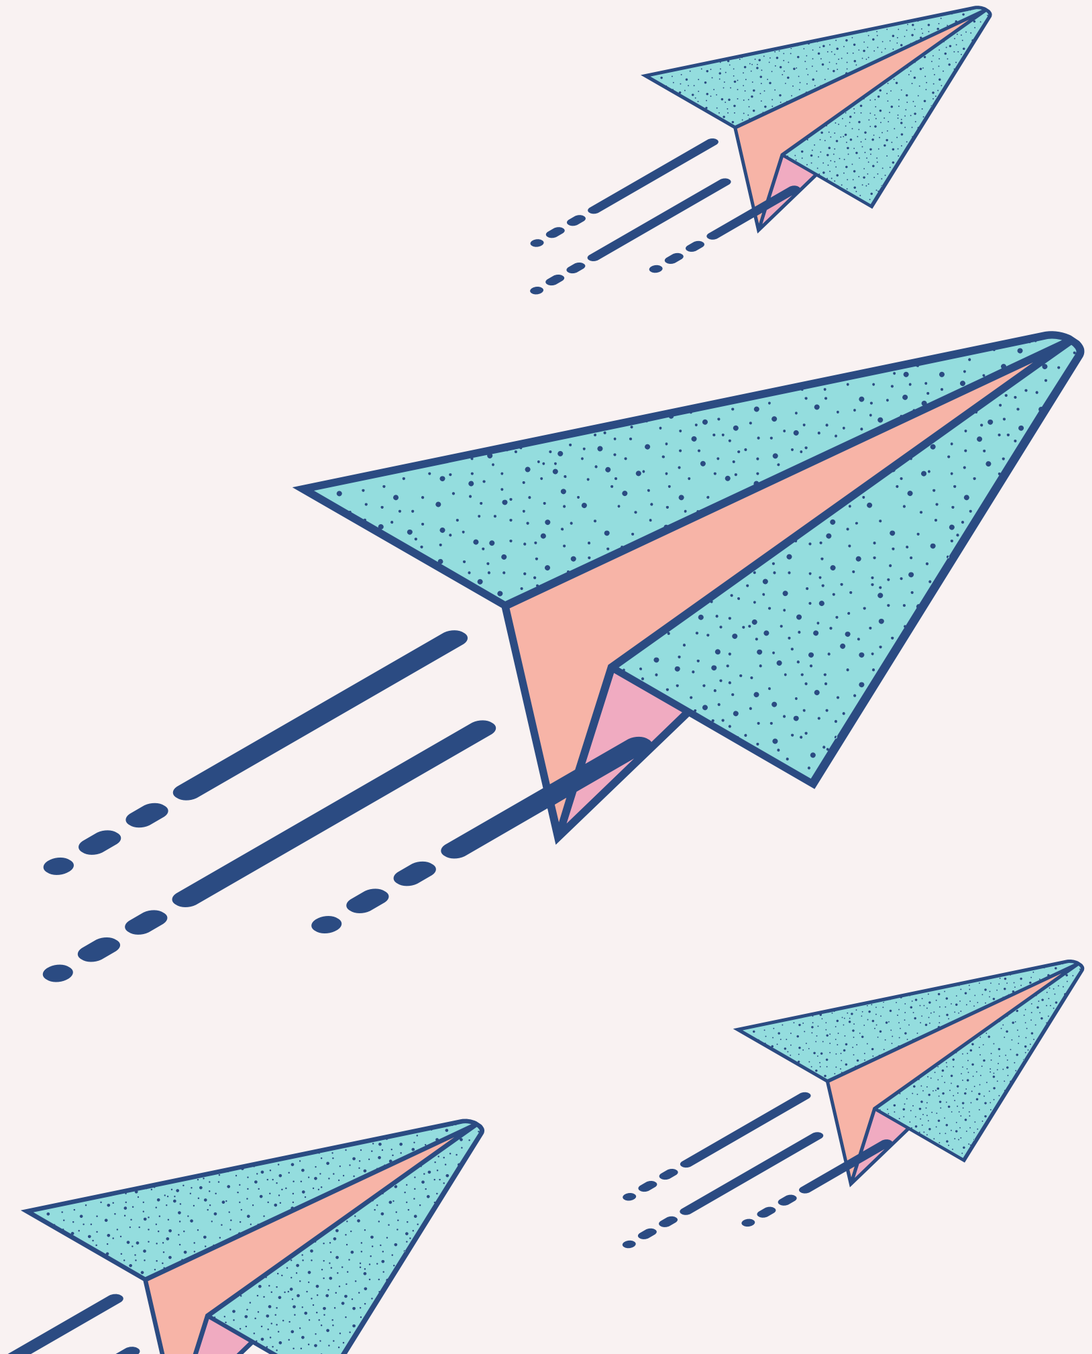

最佳化

	Model	R^2 Score	MSE
0	Gradient Boosting	0.373626	0.397136
1	XGBoost	0.364644	0.402831
2	Polynomial Regression	0.364462	0.402946
3	Ridge Regression	0.336677	0.420562
4	SVR	0.311308	0.436647
5	MLP Regressor	0.288883	0.450865
6	KNN Regressor	0.175898	0.522500

我們選擇用Polynomial Regression模型

SFS 序列特徵選擇法

我們選擇五個具有影響性的變數

- volatile acidity
- chlorides
- total sulfur dioxide
- sulphates
- alcohol

找出每個變數的係數
(by polynomial,degree=2)

```
volatile acidity                : 0.3530
chlorides                       : 7.7682
total sulfur dioxide            : 0.0026
sulphates                       : -0.1721
alcohol                         : 1.0094
volatile acidity^2              : -0.6187
volatile acidity chlorides      : 1.0257
volatile acidity total sulfur dioxide: 0.0076
volatile acidity sulphates      : 0.0324
volatile acidity alcohol        : -0.0956
chlorides^2                     : -2.5584
chlorides total sulfur dioxide: -0.0075
chlorides sulphates             : 0.2500
chlorides alcohol               : -0.8527
total sulfur dioxide^2          : 0.0000
total sulfur dioxide sulphates: -0.0099
total sulfur dioxide alcohol    : -0.0004
sulphates^2                     : -0.6334
sulphates alcohol               : 0.2666
alcohol^2                       : -0.0352
```

五個變數的邊界條件

```
volatile acidity          | Min: 0.12  Max: 1.58
chlorides                 | Min: 0.01  Max: 0.61
total sulfur dioxide      | Min: 6.00  Max: 289.00
sulphates                 | Min: 0.33  Max: 2.00
alcohol                   | Min: 8.40  Max: 14.90
```

使用 Polynomial Regression 進行品質預測

```
quality_expr = (
        0.3530 * model.va +
        7.7682 * model.ch +
        0.0026 * model.so2 +
        -0.1721 * model.su +
        1.0094 * model.al +
        -0.6187 * model.va ** 2 +
        1.0257 * model.va * model.ch +
        0.0076 * model.va * model.so2 +
        0.0324 * model.va * model.su +
        -0.0956 * model.va * model.al +
        -2.5584 * model.ch ** 2 +
        -0.0075 * model.ch * model.so2 +
        0.2500 * model.ch * model.su +
        -0.8527 * model.ch * model.al +
        0.0000 * model.so2 ** 2 +
        -0.0099 * model.so2 * model.su +
        -0.0004 * model.so2 * model.al +
        -0.6334 * model.su ** 2 +
        0.2666 * model.su * model.al +
        -0.0352 * model.al ** 2
)
```

對於好的紅酒的品質限制條件

```
model.quality_constraint = pyo.Constraint(expr=quality_expr >= 7)
```

在此條件下，我們最小化對人體有害的成分 (變數)

```
model.objective = pyo.Objective(
        expr=1000 * model.va + 1000 * model.ch + model.so2,
        sense=pyo.minimize
)
```

結果

```
volatile acidity = 0.1000
chlorides        = 0.0100
total SO2        = 10.0000
sulphates        = 0.8413
alcohol          = 10.5974
predicted quality= 8.3556
total harmfuls   = 120.0000
```

在此最小化危害條件下，我們預測的最佳品質大約為8.4

結果

```
volatile acidity = 0.1000
chlorides        = 0.0100
total SO2        = 10.0000
sulphates        = 0.8413
alcohol          = 10.5974
predicted quality= 8.3556
total harmfuls   = 120.0000
```

總體危害：

透過volatile acidity、chlorides和total SO2計算

研究結果

- 品質預測模型表現穩定

  本研究以線性回歸模型結合變數穩定性選擇法（Stability Selection）建立紅酒品質預測模型
  最終模型的均方根誤差（RMSE）為 0.577，解釋力（R-squared）為 0.4012
  約能解釋品質變異的 40%。模型尚未達完全解釋力，但已具備實際預測價值。

- 主要變數與品質關聯性明確

  酒精濃度為影響品質最顯著的正向因子（相關係數 0.48），其次為硫酸鹽與檸檬酸，
  顯示其在風味與保存上的正面效果。
  負相關因子則包括揮發性酸、密度、總二氧化硫與氯化物，可能對口感或風味造成抑制作用。

- 進一步進行品質優化模擬

  透過回歸對五個影響性變數（揮發酸、氯化物、總二氧化硫、硫酸鹽、酒精）進行品質優化模擬，
  結果顯示在特定參數條件下，可預測品質達 8.4 分，並同時控制對人體較有害成分於合理範圍內，
  具有潛在應用價值。

未來展望

- 使用國際上更通用的評分標準
- 與類似的資料集比較結果
- 探討如何建構即時監控系統